

Cap 7.6

3. $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\beta)$. Queremos M.L.E. para a mediana φ da distribuição. Como temos uma distribuição contínua, $P(X_1 \leq \varphi) = 0.5 \Rightarrow e^{-\beta\varphi} = 0.5$, pois $P(X \leq \varphi) = 1 - e^{-\beta\varphi}$. Logo $\log(e^{-\beta\varphi}) = \log(1/2) \Rightarrow -\beta\varphi = -\log 2 \Rightarrow \varphi = (\log 2)/\beta$.

Veja que se $S = \sum_{i=1}^n X_i$, $\hat{\beta} = 1/S$ é MLE para β . Defina $g(\beta) = (\log 2)/\beta$. Pela invariância do estimador $\varphi = g(\beta) \Rightarrow \hat{\varphi} = g(\hat{\beta}) = \log 2 / \hat{\beta} = S \cdot \log 2$.

Conclua que $S \cdot \log 2$ é MLE para φ .

5. $X_1, \dots, X_n \sim \text{Unif}[a, b]$. Queremos MLE para $\mu = (a+b)/2$, média da distribuição. $\begin{cases} 1, & x_i \in [a, b] \\ 0, & x_i \notin [a, b] \end{cases}$

Temos que $f_n(x|a, b) = \prod_{i=1}^n f(x_i|a, b) = \prod_{i=1}^n \frac{1}{b-a} \mathbb{1}_{\{x_i \in [a, b]\}} = \frac{1}{(b-a)^n} \mathbb{1}_{\{x_1, \dots, x_n \in [a, b]\}}$

Note que se para algum x_i , temos que $x_i \notin [a, b]$, $f_n(x|a, b) = 0$, o que é péssimo!

Logo queremos que se $1 \leq i \leq n$, $x_i \in [a, b]$. Nesse caso $f_n(x|a, b) > 0$, que é melhor.

Por outro lado, queremos minimizar $(b-a)^n$, para isso basta minimizar $b-a$. Nesse caso, tomarei $\hat{b} = \max\{x_i\}$ e $\hat{a} = \min\{x_i\}$. Se $b < \hat{b}$, existe i tal que $b < x_i$, logo $f_n(x|a, b) = 0$.

Se $b > \hat{b}$, o denominador fica maior e reduz a verossimilhança.

O mesmo vale para \hat{a} .
Logo $\hat{\mu} = \frac{\max\{x_i\} + \min\{x_i\}}{2}$ é MLE para μ dada a invariância do estimador.

11. $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Unif}[0, \theta]$. Temos mostrar que $\hat{\theta}_n \xrightarrow{P} \theta$. Pelo exercício anterior, sabemos que $\hat{\theta}_n = \max\{x_i\}_{i=1, \dots, n}$ é MLE para θ .

Sabemos que $P(X_i \leq \theta) = 1$, para todo i . Logo $P(\hat{\theta}_n \leq \theta) = 1, \forall n \in \mathbb{N}$.

Tomemos $\varepsilon > 0$.

$$\begin{aligned} P(\theta - \varepsilon < \hat{\theta}_n) &= P(\hat{\theta}_n > \theta - \varepsilon) \\ &= 1 - P(\hat{\theta}_n \leq \theta - \varepsilon) \\ &= 1 - P(X_1 \leq \theta - \varepsilon, \dots, X_n \leq \theta - \varepsilon) \\ &= 1 - P(X_1 \leq \theta - \varepsilon) \cdots P(X_n \leq \theta - \varepsilon), \text{ independência} \\ &= 1 - P(X_1 \leq \theta - \varepsilon)^n, \text{ mesma distribuição} \\ &= 1 - \left(\frac{\theta - \varepsilon}{\theta}\right)^n \rightarrow 1, \text{ quando } n \rightarrow \infty, \end{aligned}$$

pois $\theta - \varepsilon < \theta$.
Concluimos que $\hat{\theta}_n \xrightarrow{P} \theta$.

20. $X_1, \dots, X_n \sim \text{Poisson}(\theta)$

MLE: $f_n(x|\theta) = \frac{e^{-n\theta} \theta^{\sum x_i}}{\prod_{i=1}^n x_i!} \Rightarrow L(\theta|x) = -n\theta + \sum x_i \cdot \ln \theta + \sum \ln(x_i!)$

Assim $\frac{d}{d\theta} L(\hat{\theta}|x) = -n + \frac{\sum x_i}{\hat{\theta}} = 0 \Rightarrow \hat{\theta} = \bar{X}_n$

Momentos: Temos θ é 1-dimensional. Além disso $E[X_i] = \theta$ é finito. Podemos usar o método. O método amostral é $m_1 = 1/n \sum_{i=1}^n x_i$ e $\mu_1(\theta) = E[X_i|\theta] = \theta$.

Logo pelo método dos momentos $\bar{X}_n = m_1 = \mu_1(\hat{\theta}) = \hat{\theta}$

Conclua que são os mesmos estimadores.

22. $X_1, \dots, X_n \sim \text{Unif}[0, \theta]$

a) Temos que θ é 1-dimensional e $E[X|\theta] = \theta/2$ é finito. Logo podemos usar esse método. O momento amostral é $m_1 = 1/n \sum x_i = \bar{X}_n$. Além disso, $\mu_1(\theta) = E[X_i|\theta] = \theta/2$, logo $\hat{\theta} = 2\bar{X}_n$ é o estimador dos momentos.

b) Veja que $2\bar{X}_n \neq \max\{X_1, \dots, X_n\} = \bar{\theta}_{MLE}$

23. $X_1, \dots, X_n \sim \text{Beta}(\alpha, \beta)$

a) Agora $\theta = (\alpha, \beta)$ é 2-dimensional. Como média e variância estão definidos, posso usar o método. $m_1 = \bar{X}_n$ e $m_2 = 1/n \sum_{i=1}^n X_i^2$. Além disso, $\mu_1(\theta) = E[X_i|\theta] = \frac{\alpha}{\alpha+\beta}$ e $\mu_2 = E[X_i^2|\theta] = \text{Var}[X_i|\theta] + E[X_i|\theta]^2 = \frac{\alpha\beta}{(\alpha+\beta)(\alpha+\beta+1)} + \frac{\alpha^2}{(\alpha+\beta)^2}$

Pelo método: $\bar{X}_n = \frac{\hat{\alpha}}{\hat{\alpha} + \hat{\beta}}$, $\frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\hat{\alpha}}{(\hat{\alpha} + \hat{\beta})^2} \left[\frac{\hat{\beta}}{(\hat{\alpha} + \hat{\beta} + 1)} + \hat{\alpha} \right]$

$\hat{\alpha}(1 - \bar{X}_n) = \hat{\beta}\bar{X}_n \Rightarrow \hat{\alpha} = \hat{\beta} \frac{\bar{X}_n}{(1 - \bar{X}_n)}$

Logo, $\frac{1}{\bar{X}_n} \cdot \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\hat{\beta}\bar{X}_n / (1 - \bar{X}_n) + 1}{\hat{\beta}\bar{X}_n / (1 - \bar{X}_n) + \hat{\beta} + 1} = \frac{\hat{\beta}\bar{X}_n + 1 - \bar{X}_n}{\hat{\beta} + 1 - \bar{X}_n}$

$\Rightarrow (\hat{\beta} + 1 - \bar{X}_n) \sum_{i=1}^n X_i^2 = n\bar{X}_n(\hat{\beta}\bar{X}_n + 1 - \bar{X}_n)$

$\Rightarrow \hat{\beta} [\sum X_i^2 - n\bar{X}_n \cdot \bar{X}_n] = n\bar{X}_n - n\bar{X}_n^2 + \bar{X}_n \sum_{i=1}^n X_i^2 - \sum_{i=1}^n X_i^2$

$\Rightarrow \hat{\beta} = \frac{n[\bar{X}_n - \bar{X}_n^2] + \bar{X}_n \cdot \bar{X}_n^2 - \bar{X}_n^2}{n[\bar{X}_n^2 - \bar{X}_n^2]} = \frac{\bar{X}_n(1 - \bar{X}_n) - \bar{X}_n^2(1 - \bar{X}_n)}{[\bar{X}_n^2 - \bar{X}_n^2]}$

$= \frac{(1 - \bar{X}_n)(\bar{X}_n - \bar{X}_n^2)}{\bar{X}_n^2 - \bar{X}_n^2}$

Por fim $\hat{\alpha} = \frac{(1 - \bar{X}_n)(\bar{X}_n - \bar{X}_n^2)}{\bar{X}_n^2 - \bar{X}_n^2} \cdot \frac{\bar{X}_n}{(1 - \bar{X}_n)}$

b) $f_n(x|\theta) = \frac{(\prod x_i)^{\alpha-1} (\prod (1-x_i))^{\beta-1}}{B(\alpha, \beta)^n} =$

$L(\theta|x) = (\alpha-1) \sum \ln(x_i) + (\beta-1) \sum \ln(1-x_i) - n \cdot \ln(B(\alpha, \beta))$
 $= (\alpha-1) \sum \ln(x_i) + (\beta-1) \sum \ln(1-x_i) - n[\ln(\Gamma(\alpha)) + \ln(\Gamma(\beta)) - \ln(\Gamma(\alpha+\beta))]$

$\frac{\partial L}{\partial \alpha} = \sum \ln(x_i) - n \cdot \frac{\Gamma'(\alpha)}{\Gamma(\alpha)} + \frac{\Gamma'(\alpha+\beta)}{\Gamma(\alpha+\beta)} \cdot 1 \xrightarrow{\frac{d}{d\alpha}(\alpha+\beta)} = 0$

Note que o valor envolverá $\sum \ln(x_i)$ que não aparece no método de momentos, logo não será o mesmo.